

PREDITION REALESTATE PRICES IN BKK

Present by Eat & Drink

AGENDA

1 Introduction

2 Problem Statement

3 Objective

4 Expectation

5 ML Canvas

6 Workflow Diagram

7 Workflow

8 Model Development

9 แสดงผลการประเมิน

10 System Architecture Diagram

11 Web Demo

12 Member



INTRODUCTION

การทำนายราคาสังหาริมทรัพย์ในแต่ละพื้นที่ของกรุงเทพฯ มีความสำคัญอย่างยิ่งในหลายมิติ ประการแรก ช่วยให้ผู้อยู่และผู้ซื้อและนักลงทุนสามารถวางแผนการเงินและตัดสินใจเลือกทำเลที่เหมาะสมกับงบประมาณและความต้องการ ประการที่สอง ผู้พัฒนาโครงการสามารถใช้ข้อมูลการทำนายราคาเพื่อกำหนดแผนการลงทุนและพัฒนาโครงการที่ตอบโจทย์ตลาดได้ดีขึ้น ประการที่สาม หน่วยงานภาครัฐหรือองค์กรด้านผังเมืองสามารถนำข้อมูลเหล่านี้ไปใช้ในการวางแผนพัฒนาเมืองอย่างมีประสิทธิภาพ นอกจากนี้ยังช่วยลดความเสี่ยงและสร้างความโปร่งใสในตลาดอสังหาริมทรัพย์





PROBLEM STATEMENT

Lack of location Differentiation

ในปัจจุบัน ราคาอสังหาริมทรัพย์ในกรุงเทพฯ มีความแตกต่างกันอย่างมากในแต่ละพื้นที่ ทั้งนี้เนื่องจากปัจจัยด้านทำเลที่ตั้ง การเข้าถึงระบบขนส่งสาธารณะ สิ่งอำนวยความสะดวกโดยรอบ รวมถึงแนวโน้มการเติบโตทางเศรษฐกิจและอสังหาริมทรัพย์ ปัญหาที่สำคัญคือผู้ซื้อ นักลงทุนและผู้พัฒนาโครงการขาดข้อมูลเชิงลึกที่สามารถทำนายราคาอสังหาริมทรัพย์ในแต่ละพื้นที่ได้อย่างแม่นยำ ส่งผลให้เกิดความเสี่ยงในการตัดสินใจและอาจทำให้เกิดความไม่สมดุลของตลาด




OBJECTIVE

- เพื่อศึกษาปัจจัยที่มีผลต่อราคาอสังหาริมทรัพย์ในแต่ละพื้นที่ของกรุงเทพฯ
- เพื่อพัฒนาแบบจำลองสำหรับทำนายราคาอสังหาริมทรัพย์ในแต่ละทำเลอย่างแม่นยำ
- เพื่อสร้างเครื่องมือสนับสนุนการตัดสินใจสำหรับผู้ซื้อ นักลงทุน และผู้พัฒนาอสังหาริมทรัพย์





EXPECTATION



- ได้แบบจำลองหรือเครื่องมือที่สามารถทำนายราคาอสังหาริมทรัพย์ในแต่ละพื้นที่ของกรุงเทพฯ ได้อย่างแม่นยำ
- มีข้อมูลเชิงลึกเกี่ยวกับปัจจัยที่มีผลต่อราคาอสังหาริมทรัพย์ในแต่ละทำเล
- ช่วยให้ผู้เกี่ยวข้องในตลาดอสังหาริมทรัพย์ตัดสินใจได้อย่างมีประสิทธิภาพและลดความเสี่ยง
- ส่งเสริมความโปร่งใสและสมดุลในตลาดอสังหาริมทรัพย์กรุงเทพฯ

MACHINE LEARNING CANVAS

3. PREDICTION TASK

- Regression – Predict continuous price value (THB) from property attributes.
- INPUT:
 - Area
 - Bedrooms
 - Bathrooms
 - Property Type
- OUTPUT:
 - Price




6. DECISIONS

- ผลลัพธ์ของโมเดลช่วยให้ผู้ใช้สามารถเปรียบเทียบราคาตลาดและกำหนดราคาซื้อ-ขายที่เหมาะสม



1. VALUE PROPOSITION

- พัฒนาเครื่องมือ Machine Learning สำหรับ ทำนายราคาที่อยู่อาศัยในกรุงเทพฯ เพื่อช่วยผู้ซื้อ นักลงทุน และผู้พัฒนาโครงการตัดสินใจเชิงกลยุทธ์อย่างมีประสิทธิภาพ และสร้างความโปร่งใสในตลาดอสังหาริมทรัพย์



8. DATA COLLECTION

- รวบรวมข้อมูลอสังหาริมทรัพย์ จากเว็บต่าง ๆ อย่างต่อเนื่อง
- ใช้ DVC จัดการเวอร์ชันข้อมูล เพื่อให้ระบบสามารถอัปเดตและตรวจสอบซ้ำได้ง่าย



2. DATA SOURCES

- Dataset: Bangkok Housing, Condo, Apartment Prices.csv
- แหล่งข้อมูลจากเว็บไซต์ DDproperty, Hipflat, และ Kaggle




5. OFFLINE EVALUATION

- Metrics: $R^2 = 0.9363$, RMSE = 674,391 THB, MAE = 288,495 THB
- Validation: 70/30 Train-Test split
- Tools: ML flow for tracking runs and Evidently AI for drift detection

7. MAKING PREDICTIONS

- โมเดลถูกนำขึ้นออนไลน์ผ่าน Fast API endpoint /predict และเปิดให้ใช้งานผ่านเว็บ
- ผู้ใช้สามารถกรอกข้อมูลอสังหาริมทรัพย์ แล้วระบบจะแสดงราคาที่ทำนายได้แบบเรียลไทม์



9. BUILDING MODELS

- ทรูโมเดล Random Forest ด้วย Python + ML flow
- Pipeline ครบขั้นตอน ตั้งแต่ Cleaning ถึง Evaluation
- แพคเกจด้วย Docker เพื่อ deploy ได้อย่างเสถียร


4. FEATURES

- Numerical: Area, Bedrooms, Bathrooms
- Categorical: Property Type (Apartment, Condo, House)

10. LIVE MONITORING

- ตรวจสอบคุณภาพโมเดลจริงด้วย Evidently AI
- ติดตามค่าประสิทธิภาพผ่าน ML flow
- Retrain โมเดลเมื่อความแม่นยำเริ่มลดลง

WORKFLOW DIAGRAM



รวบรวมและจัดการข้อมูล

ดึงข้อมูลจากเว็บไซต์
อสังหาริมทรัพย์หรือฐานข้อมูล
ภายใน เช่น DDproperty,
Hipflat, Kaggle

02



วิเคราะห์ข้อมูลเบื้องต้น (EDA)

ใช้ Pair Plot เพื่อดูความสัมพันธ์
ระหว่างพื้นที่, ห้องนอน, ห้องน้ำ,
และราคา และใช้ Scatterplot
matrix กับ Heatmap เพื่อดูความ
สัมพันธ์ระหว่างตัวแปร เช่น
ประเภทที่พักกับราคา

04



ประเมินผลโมเดล

ใช้ R^2 , RMSE, MAE เพื่อวัด
ความแม่นยำของโมเดลและ
เปรียบเทียบผลลัพธ์

06



ทำความสะอาดและแปลงข้อมูล

จัดการ missing values,
outliers และแปลงข้อมูล
categorical เป็น dummy
variables

03



สร้างและเทรนโมเดล ML

ใช้ KNN หรือโมเดลอื่น ๆ
พร้อม MLflow สำหรับจัดการ
เวอร์ชันและบันทึกผลการเทรน

05



นำโมเดลไปใช้งานจริง

พัฒนา API ด้วย FastAPI,
deploy ด้วย Docker และ
Render รวมถึง Front-end
เพื่อให้ User ใช้งานได้

01



PROCESS

ขั้นตอน	วัตถุประสงค์	เครื่องมือ MLOps
1. Project Initiation	กำหนดปัญหา, วัตถุประสงค์ (ทำนายราคา), และตั้งค่า Git Repository	Git / GitHub
2. Data Acquisition	รวบรวมข้อมูลอสังหาริมทรัพย์ (Bangkok Housing Condo Apartment Prices CSV)	Git / DVC
3. Data Preprocessing	ทำความสะอาดข้อมูล, Feature Engineering (OHE Type), และ Train/Test Split	DVC (Output V2)
4. Model Training	ฝึก Random Forest Regressor	MLflow (Tracking Run)
5. Experiment Tracking	บันทึก Hyperparameters และ Metrics (RMSE)	MLflow
6. Model Evaluation	ประเมินผลลัพธ์บน Test Set และตรวจสอบคุณภาพ (EvidentlyAI)	EvidentlyAI
7. API & Containerization	สร้าง app.py (FastAPI) และ Dockerfile	FastAPI, Docker
8. Build Docker Image	สร้าง Image สำหรับที่บรรจุ Model และ API	Docker
9. Push to Docker Hub	อัปโหลด Image ไปยัง Registry	Docker Hub
10. Cloud Deployment	รัน Docker Container บน Cloud Server	Render
11. API Endpoint	เปิดให้บริการ API (/predict)	FastAPI, Uvicorn
12. Web Demo	Frontend (HTML/JS) เรียก API เพื่อแสดงผลลัพธ์	



MODEL DEVELOPMENT

การเลือกแบบจำลอง (MODEL SELECTION)

Regression (การทำนายค่าต่อเนื่อง) โดยแบบจำลองที่เลือกเป็น Random Forest Regressor เนื่องจาก Ensemble Model มีประสิทธิภาพสูงสำหรับ Tabular Data (ข้อมูลเชิงตาราง) เช่น ข้อมูลอสังหาริมทรัพย์ เนื่องจาก

- 1. ความแม่นยำสูง:** สามารถจัดการกับความสัมพันธ์แบบ Non-linear (ไม่เป็นเส้นตรง) ระหว่างฟีเจอร์ต่าง ๆ (เช่น พื้นที่กับทำเล) ได้ดีกว่า Linear Model
- 2. ความทนทานต่อ Outliers:** ทนทานต่อค่าผิดปกติ (Outliers) ในข้อมูลราคาเช่าได้ดี
- 3. ความสำคัญของฟีเจอร์:** สามารถระบุความสำคัญของฟีเจอร์ต่าง ๆ ได้ (Feature Importance) ซึ่งช่วยในการทำความเข้าใจว่าปัจจัยใดมีผลต่อราคาเช่ามากที่สุด

MODEL DEVELOPMENT

เทคนิคที่ใช้ในการจัดการข้อมูล (FEATURE ENGINEERING)

โมเดลถูกฝึกด้วย FEATURES ทั้งหมด 4 ตัว ซึ่งต้องผ่านการแปลงข้อมูลเพื่อให้โมเดลสามารถใช้งานได้:

1.การจัดการข้อมูลประเภทตัวเลข (Numerical Features) :

- Features: Area (sq. ft.), Bedrooms, Bathrooms
- การจัดการ: มีการจัดการ Missing Values (หากมี) ด้วยการเติมค่าเฉลี่ยหรือค่ามัธยฐาน

2.การจัดการข้อมูลประเภทหมวดหมู่ (Categorical Features) :

- Feature: property_type (Apartment, Condo, House)
- เทคนิคที่ใช้: One-Hot Encoding (OHE)
- ผลลัพธ์: แปลงจาก 1 คอลัมน์ เป็น 3 คอลัมน์ย่อย (Type_Apartment, Type_Conado, Type_House) โดยมีค่าเป็น 0 หรือ 1 เพื่อให้โมเดลสามารถคำนวณได้ ซึ่งการทำ OHE นี้ถูกผนวกเอาไว้ใน FastAPI เพื่อให้การรับ Input จากผู้ใช้งานทำได้ง่ายขึ้น

MODEL DEVELOPMENT

การติดตามผลการทดลอง (EXPERIMENT TRACKING)


ใช้ MLflow เพื่อบันทึก Hyperparameters ของ Random Forest, บันทึก Metrics (RMSE) ที่ได้จากแต่ละรอบการฝึก, และเก็บ Model Artifact (ไฟล์โมเดล .pkl) ทำให้สามารถเปรียบเทียบประสิทธิภาพของโมเดล Version ต่าง ๆ ได้อย่างเป็นระบบ

ผลลัพธ์ที่ได้จากการประเมิน (METRICS)

- ค่า RMSE แสดงถึงค่าเฉลี่ยความคลาดเคลื่อนของการทำนายราคาเมื่อเทียบกับราคาจริง ยิ่งค่านี้ต่ำเท่าใด โมเดลยิ่งแม่นยำมากขึ้นเท่านั้น
- Model Validation: มีการใช้ Evidently AI เพื่อตรวจสอบคุณภาพของโมเดลและข้อมูล (Data Drift / Model Drift) ก่อนการตัดสินใจนำไป Deploy

ความสัมพันธ์ระหว่างตัวแปรด้วย PAIRWISE RELATIONSHIPS (SCATTERPLOT MATRIX)

แสดงผลการประเมิน



Scatterplot สำหรับทุกคู่ของตัวแปร และกราฟ KDE (Kernel Density Estimate) บนแนวทแยงเพื่อแสดงการกระจายตัวของแต่ละตัวแปร โดยข้อมูลถูกแบ่งตามทำเลที่ตั้ง เช่น สุขุมวิท, สาทร, อารี, ทองหล่อ เป็นต้น

จากการวิเคราะห์พบว่า:

- พื้นที่มีแนวโน้มสัมพันธ์เชิงบวกกับราคาล่วงคือ อสังหาริมทรัพย์ที่มีพื้นที่มากมักมีราคาสูงขึ้นตาม
- จำนวนห้องนอนและห้องน้ำมีความสัมพันธ์กันโดย อสังหาริมทรัพย์ที่มีห้องนอนมากมักมีห้องน้ำมากตามไปด้วย
- ความแตกต่างด้านราคาตามทำเล เช่น ทำเลใจกลางเมือง อย่าง ทองหล่อ หรือ สีลม มีราคาสูงแม้พื้นที่ไม่มาก ในขณะที่ พื้นที่รอบนอกอย่างลาดพร้าวมีพื้นที่มากแต่ราคาต่ำกว่า

ความสัมพันธ์ระหว่างตัวแปรด้วย HEATMAP

แสดงผลการประเมิน



- Price (THB) มีความสัมพันธ์เชิงบวกสูงกับ Type_House (0.81) หมายความว่า บ้าน (House) มีแนวโน้มราคาสูงกว่าประเภทอื่น
- Price (THB) มีความสัมพันธ์เชิงลบกับ Type_Apartment (-0.58) หมายความว่า อพาร์ทเมนต์ (Apartment) มีแนวโน้มราคาต่ำกว่าประเภทอื่น
- Type_Condo มีความสัมพันธ์เชิงลบเล็กน้อยกับ Price (THB) (-0.24) ราคาคอนโดมีแนวโน้มต่ำกว่าบ้านแต่สูงกว่าอพาร์ทเมนต์
- ความสัมพันธ์ระหว่างประเภทที่พัก:
 - Type_Apartment กับ Type_Condo: -0.49
 - Type_Condo กับ Type_House: -0.53

แสดงว่าประเภทที่พักมีลักษณะเฉพาะที่แยกจากกันชัดเจนและไม่ค่อยเกิดร่วมกันในข้อมูลเดียว


ผลลัพธ์จากการรันโมเดล MACHINE LEARNING โดยใช้ MLFLOW แสดงผลลัพธ์ดังนี้

- Test R^2 Score: 0.9363 หมายถึงโมเดลสามารถอธิบายความแปรปรวนของราคาตลาดอสังหาริมทรัพย์ได้ถึง 93.63% ซึ่งถือว่าแม่นยำมาก
- Test RMSE: 674,391.24 THB เป็นค่าความคลาดเคลื่อนเฉลี่ยแบบรากสแควร์ หมายถึง โดยเฉลี่ยแล้วโมเดลพยากรณ์ราคาตลาดเคลื่อนประมาณ 674,000 บาท
- Test MAE: 288,495.58 THB เป็นค่าความคลาดเคลื่อนเฉลี่ยแบบสัมบูรณ์ หมายถึง โมเดลพยากรณ์ราคาตลาดเคลื่อนเฉลี่ยประมาณ 288,000 บาท

ผลลัพธ์นี้แสดงว่าโมเดล KNN ที่สร้างมีประสิทธิภาพดีมากในการพยากรณ์ราคาตลาดอสังหาริมทรัพย์ โดยมีค่า R^2 สูง และค่าความคลาดเคลื่อนอยู่ในระดับที่ยอมรับได้สำหรับงานด้านอสังหาริมทรัพย์ การจัดการผ่าน MLflow ยังช่วยให้สามารถติดตามเวอร์ชันของโมเดลและผลการทดลองได้อย่างเป็นระบบ


```
/usr/local/lib/python3.12/dist-packages/mlflow/types/utils.py:452: UserWarning: Hint: Inferred
warnings.warn(
2025/10/23 13:59:09 WARNING mlflow.models.model: `artifact_path` is deprecated. Please use `name`
Test R2 Score: 0.9363
Test RMSE: 674391.24 THB
Test MAE: 288495.58 THB
Run logged under 'bkk_condo_prices-knn-v1-encoded' (ID: 73e1d0f8a4b3471686f59c610c9c0fde)
Registered model 'bkk_condo_prices_knn_model' already exists. Creating a new version of this model
Created version '3' of model 'bkk_condo_prices_knn_model'.
```

SYSTEM ARCHITECTURE DIAGRAM



WEB DEMO : PREDITION REAL ESTATE PRICES IN BKK

<https://condo-predictor-latest.onrender.com/>



Bangkok Condo Price Predictor

Area (sq.ft.):
1000

Bedrooms:
1

Bathrooms:

Property Type:
Apartment

Predict Price

MEMBER

เพ็ญพิไล เพ็ญริสาร (68056081)

วาง WORKFLOW และ SYSTEM
ARCHITECTURE DIAGRAM
สร้าง APP.PY (FASTAPI) และ
DOCKERFILE



วาริศาภัสสร วรณประทีป (68056097)

ทำ EXPERIMENT TRACKING &
HYPERPARAMETERS และ
METRICS (RMSE)



ณัฐชิวา มาลากร (68056034)

ตรวจสอบคุณภาพ
(EVIDENTLYAI) และแก้ไข CODE
เพื่อให้ขึ้น FRONT END ได้



นพพร ครองญาติ (68056056)

จัดการ DOCKER
(BUILD,PUSH), รัน DOCKER
CONTAINER บน CLOUD
SERVER ผ่าน RENDER



เปมิกา ศักดิ์ศิริศิลป์ (68056069)

DATA PREPROCESSING และ
ทำการ TRAIN MODEL
(PYTHON)





THANKYOU

for your time and attention

ณัฐชิวา มาลากร (68056034)
นวพร ครองญาติ (68056056)
เปมิภา ศักดิ์ศิริศิลป์ (68056069)
เพ็ญพิไล เพ็ญริสาร (68056081)
วาริตาภัสสร วรณประทีป (68056097)

